


NEUROSCIENCE

# Dynamic prospect theory: Two core decision theories coexist in the gambling behavior of monkeys and humans

Agnieszka Tymula<sup>1\*</sup>, Xueting Wang<sup>2</sup>, Yuri Imaizumi<sup>3</sup>, Takashi Kawai<sup>4</sup>, Jun Kunimatsu<sup>4,5,6</sup>, Masayuki Matsumoto<sup>4,5,6</sup>, Hiroshi Yamada<sup>4,5,6\*</sup>



動的プロスペクト理論：  
サルとヒトのギャンブル行動において共存する  
2つの中核的意思決定理論

名古屋大学理学部 1 年  
尾崎晴美

# 自己紹介




尾崎晴美

愛知県立岡崎高校



名古屋大学理学部 1 年



自然科学研究機構  
生理学研究所

10/28 一般公開



# 著者

---

Professor. Agnieszka Tymula



Ph.D. in Economics, Bocconi University  
School of Economics,  
University of Sydney  
行動経済学、神経経済学、実験経済学

山田洋 准教授





京都府立医科大学 博士(医学)  
筑波大学 医学医療系  
神経経済学、計算神経科学、神経生理学、  
行動経済学

# 神經経済学

---

神經経済学

経済学 + 神経科学



# Outline

---


-

# プロスペクト理論

---

Kahneman & Tversky (1979)

人は不確実な利得に対してリスク回避的になる一方で  
不確実な損失に対してはリスク追求的になる




川見 文紀, リスク回避に影響を及ぼす防災リテラシーとハザードリスク及び人的・物的被害認知とのノンリニアな交互作用に関する研究:2015年兵庫県県民防災意識調査の結果をもとに, 地域安全学会論文集(2016)

# プロスペクト理論

## Kahneman & Tversky (1979)

人は不確実な利得に対してリスク回避的になる一方で不確実な損失に対してはリスク追求的になる




川見 文紀, リスク回避に影響を及ぼす防災リテラシーとハザードリスク及び人的・物的被害認知とのノンリニアな交互作用に関する研究:2015年兵庫県県民防災意識調査の結果をもとに, 地域安全学会論文集(2016)

# プロスペクト理論

## Kahneman & Tversky (1979)

人は不確実な利得に対してリスク回避的になる一方で不確実な損失に対してはリスク追求的になる



川見 文紀, リスク回避に影響を及ぼす防災リテラシーとハザードリスク及び人的・物的被害認知とのノンリニアな交互作用に関する研究:2015年兵庫県県民防災意識調査の結果をもとに, 地域安全学会論文集(2016)



# 強化学習理論

---

## 「強化学習」

- ・ 行動心理学＋最適制御
- ・ 最適制御を求める問題設定
- ・ 行動に基づく経験の強化

# 強化学習理論

---

## 「強化学習」

「行動心理学」による制御      「高度制御を求めた明瞭状況」

### プロスペクト理論

➡ どういったリスクをとるかに焦点

### 強化学習理論

➡ リスク選択のあとの結果からの学習に焦点

# 強化学習理論

## 「強化学習」

「行動心理学」による制御      「高度制御を求めた明瞭状況

### プロスペクト理論

➡ どういったリスクをとるかに焦


### 強化学習理論

➡ リスク選択のあとの結果からの学習に焦点



# プロスペクト理論から考える

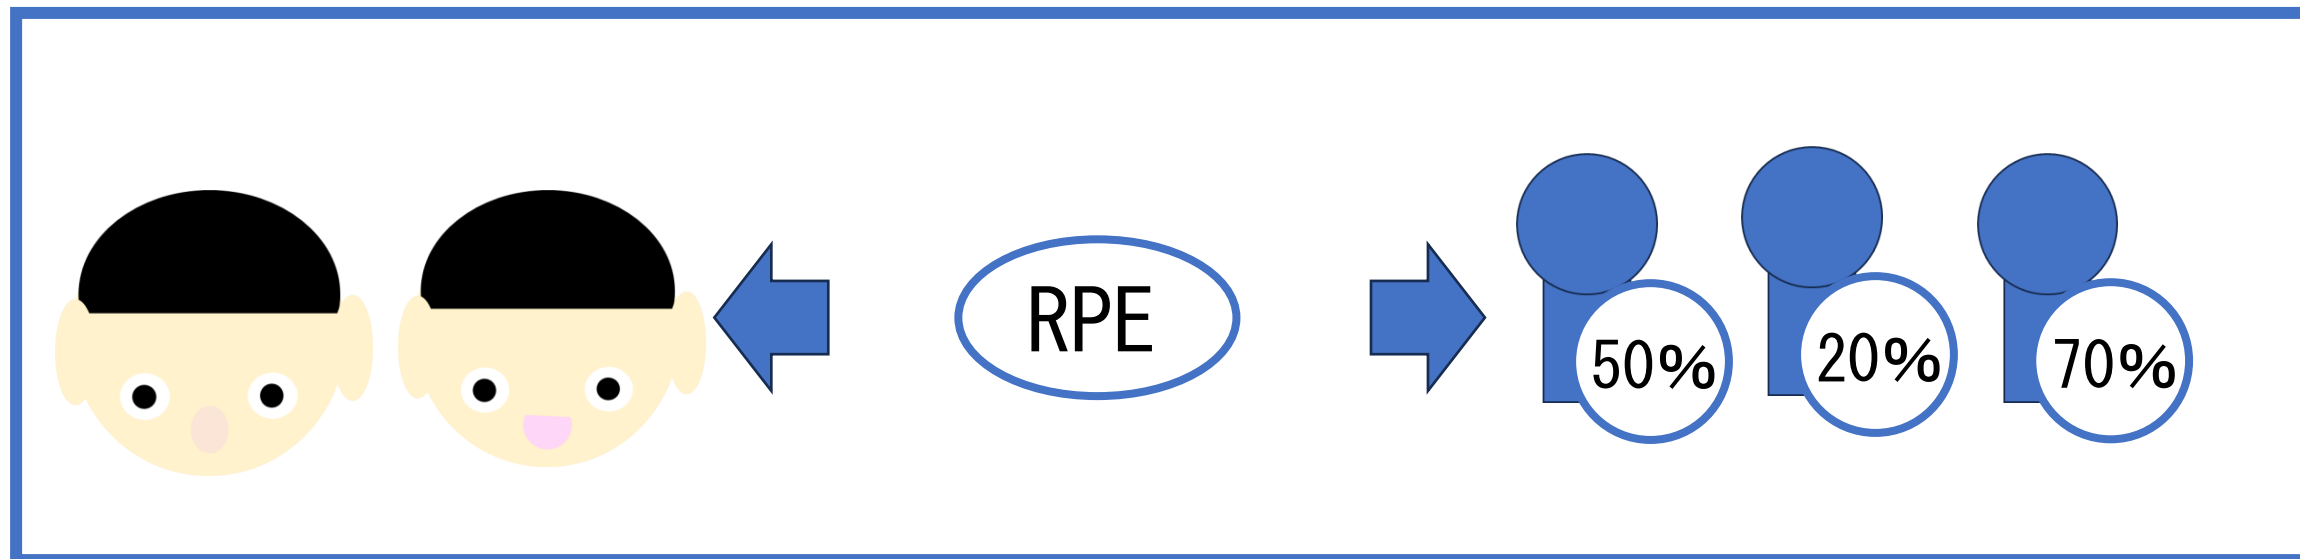
- ・ 報酬の望ましさをとらえる効用関数の曲率
- ・ 逆S字型確率加重関数の曲率
- ・ (利得の場合のみに注目)



系統的な変化？

# 強化学習理論から考える



- ・ 意思決定者がすべての選択肢の値を学習すると仮定
- ・ 報酬の経験から利用可能な選択肢の値をどのように学習するか
- ・ 報酬予測誤差（RPE）を計算することによって動的に更新  
(RPE：得られた報酬の値と、脳内で信号化された予測値との差)



# 動的プロスペクト理論


## プロスペクト理論から考える

- ・報酬の望ましさをとらえる効用関数の曲率
- ・逆S字型確率加重関数の曲率
- ・（利得の場合のみに注目）



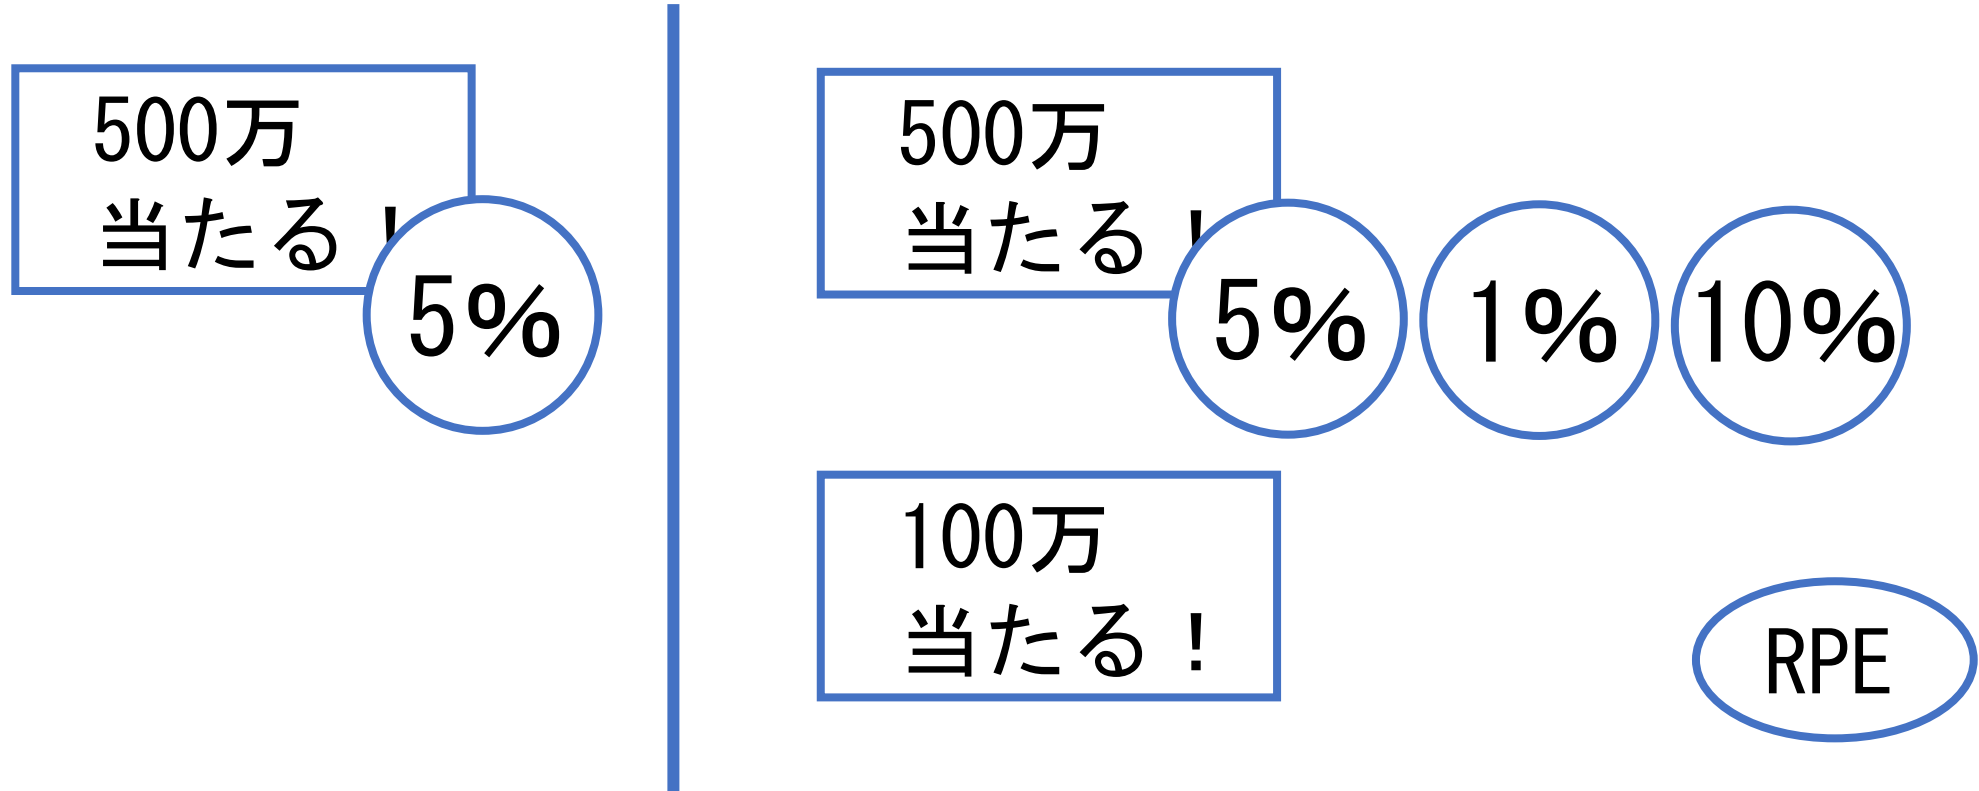
## 強化学習理論から考える

- ・意思決定者がすべての選択肢の値を学習すると仮定
- ・報酬の経験から利用可能な選択肢の値をどのように学習するか
- ・報酬予測誤差（RPE）を計算することによって動的に更新  
(RPE: 得られた報酬の値と、脳内で信号化された予測値との差)

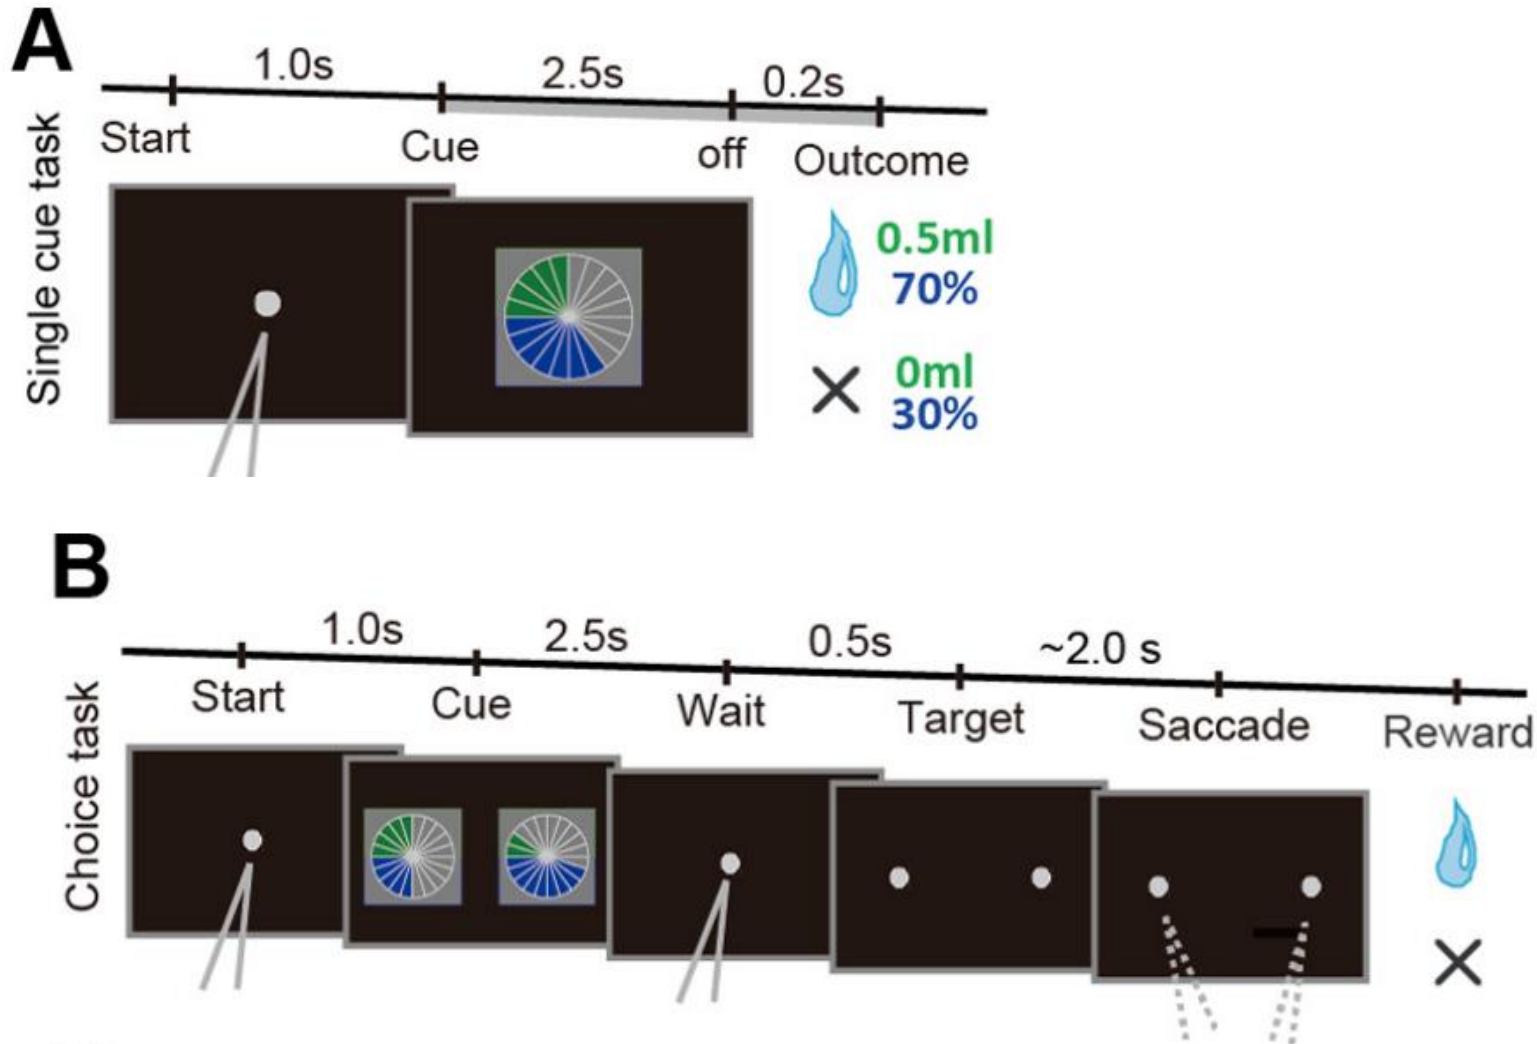


# 実験方法

---



# 実験方法 | サル




Yamada et al., Neural Dynamics for Expected Value Computation,  
The Journal of Neuroscience, February 24, 2021



# 実験方法 | ヒト

- ・ 報酬は水ではなくお金
- ・ 訓練ではなく指示書



# プロスペクト理論パラメータの推定

---

- ・ 効用関数 :  $U(m) = m^\alpha$

( $m$  : 報酬の大きさ,

$\alpha > 1$  : リスク追求,  $\alpha < 1$  : リスク回避,  $\alpha = 1$  : リスク中立 )

- ・ 確率加重関数 : 1パラメータ関数と2パラメータ関数

報酬の大きさ $m$ を確率 $p$ で受け取る  
 $V(m, p)$ の6つのモデルを推定した

# プロスペクト理論パラメータの推定

---

## 6つのモデル

- (i) EV: expected value  $V(m, p) = pm$
- (ii) EU: expected utility  $V(m, p) = pm^\alpha$
- (iii) TK: prospect theory with  $w(p)$  as in Kahneman and Tversky

$$V(m, p) = \frac{p^\gamma}{[p^\gamma + (1 - p)^\gamma]^{1/\gamma}} m^\alpha$$

# プロスペクト理論パラメータの推定

---

(iv) P1: prospect theory with  $w(p)$  with one parameter as in Prelec (63)

$$V(m, p) = \exp[-(-\log p)^\gamma] m^\alpha$$

(v) P2: prospect theory with  $w(p)$  with two parameters as in Prelec (63)

$$V(m, p) = \exp[-\delta(-\log p)^\gamma] m^\alpha$$

(vi) GE: prospect theory with  $w(p)$  as in Goldstein and Einhorn (64)

$$V(m, p) = \frac{\delta p^\gamma}{\delta p^\gamma + (1 - p)^\gamma} m^\alpha$$

# プロスペクト理論パラメータの推定

(iv) P1: prospect theory with  $w(p)$  with one parameter as in Prelec (63)

$$V(m, p) = \exp[-(-\log p)^\gamma] m^\alpha$$

(v) P2: prospect theory with  $w(p)$  with two parameters as in Prelec (63)

6つのモデルから、今回の実験に最適なものを  
みつけるため、BIC(ベイズ情報量基準)を用いた

$$V(m, p) = \frac{\delta p^\gamma}{\delta p^\gamma + (1 - p)^\gamma} m^\alpha$$

# BIC(ベイズ情報量基準)とは

---

エビデンスのラプラス近似

エビデンス

$$m(y) = \int L(y \mid \theta) p(\theta) d\theta \qquad BF(1, 2) := \frac{\int L(y \mid \theta_1) p(\theta_1) d\theta_1}{\int L(y \mid \theta_2) p(\theta_2) d\theta_2}$$

(ベイズの定理より周辺尤度)

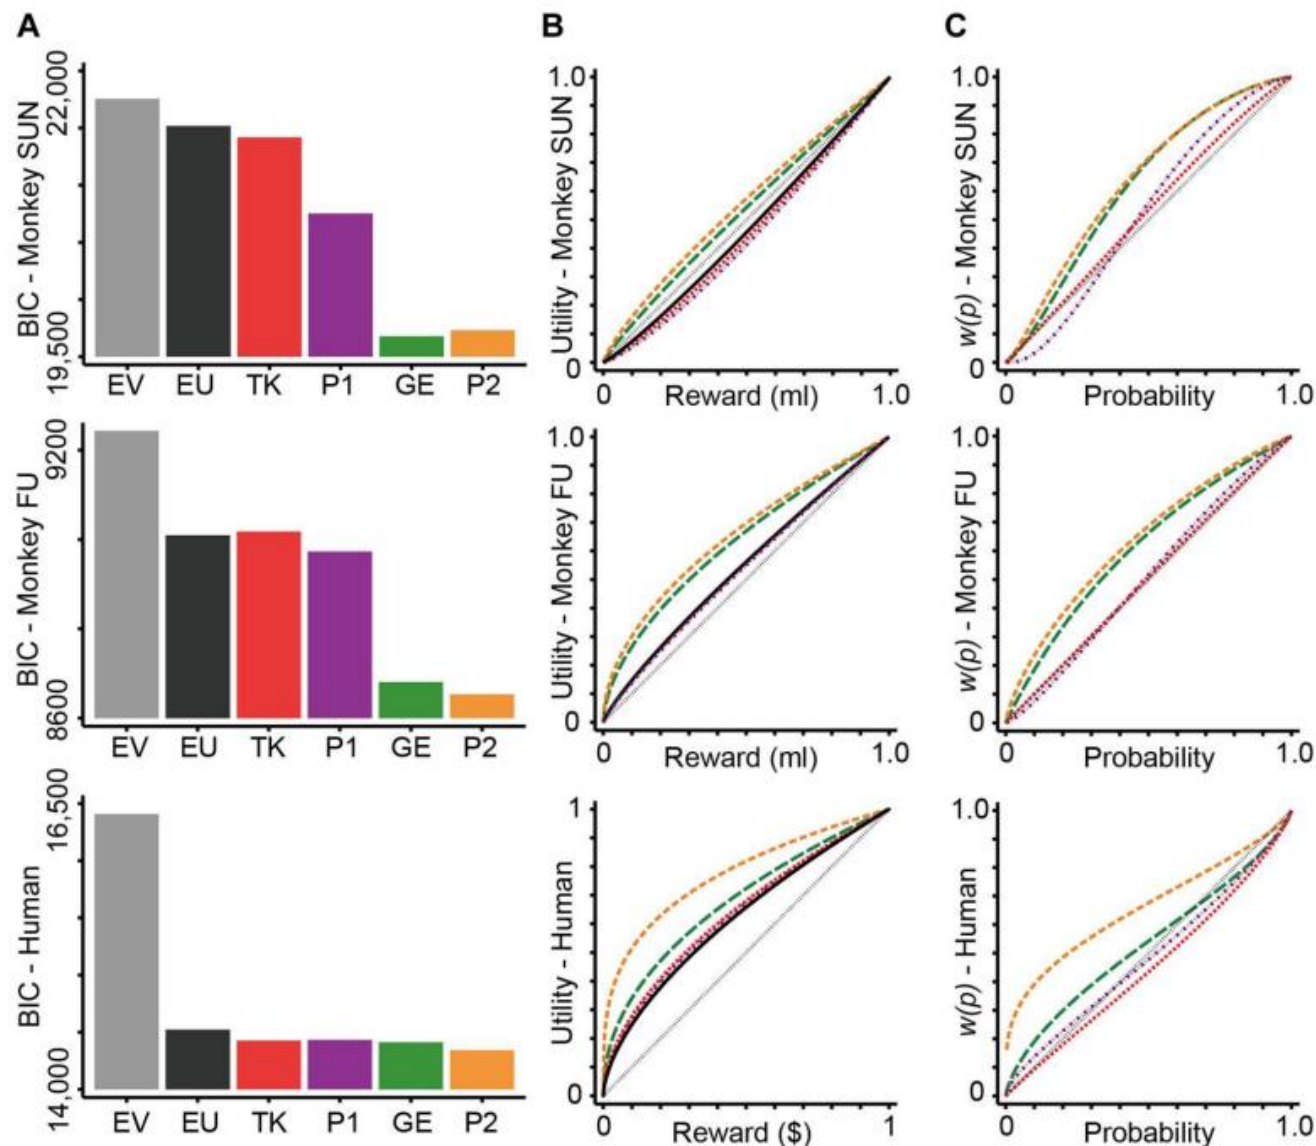
ラプラス近似

# プロスペクト理論パラメータの推定

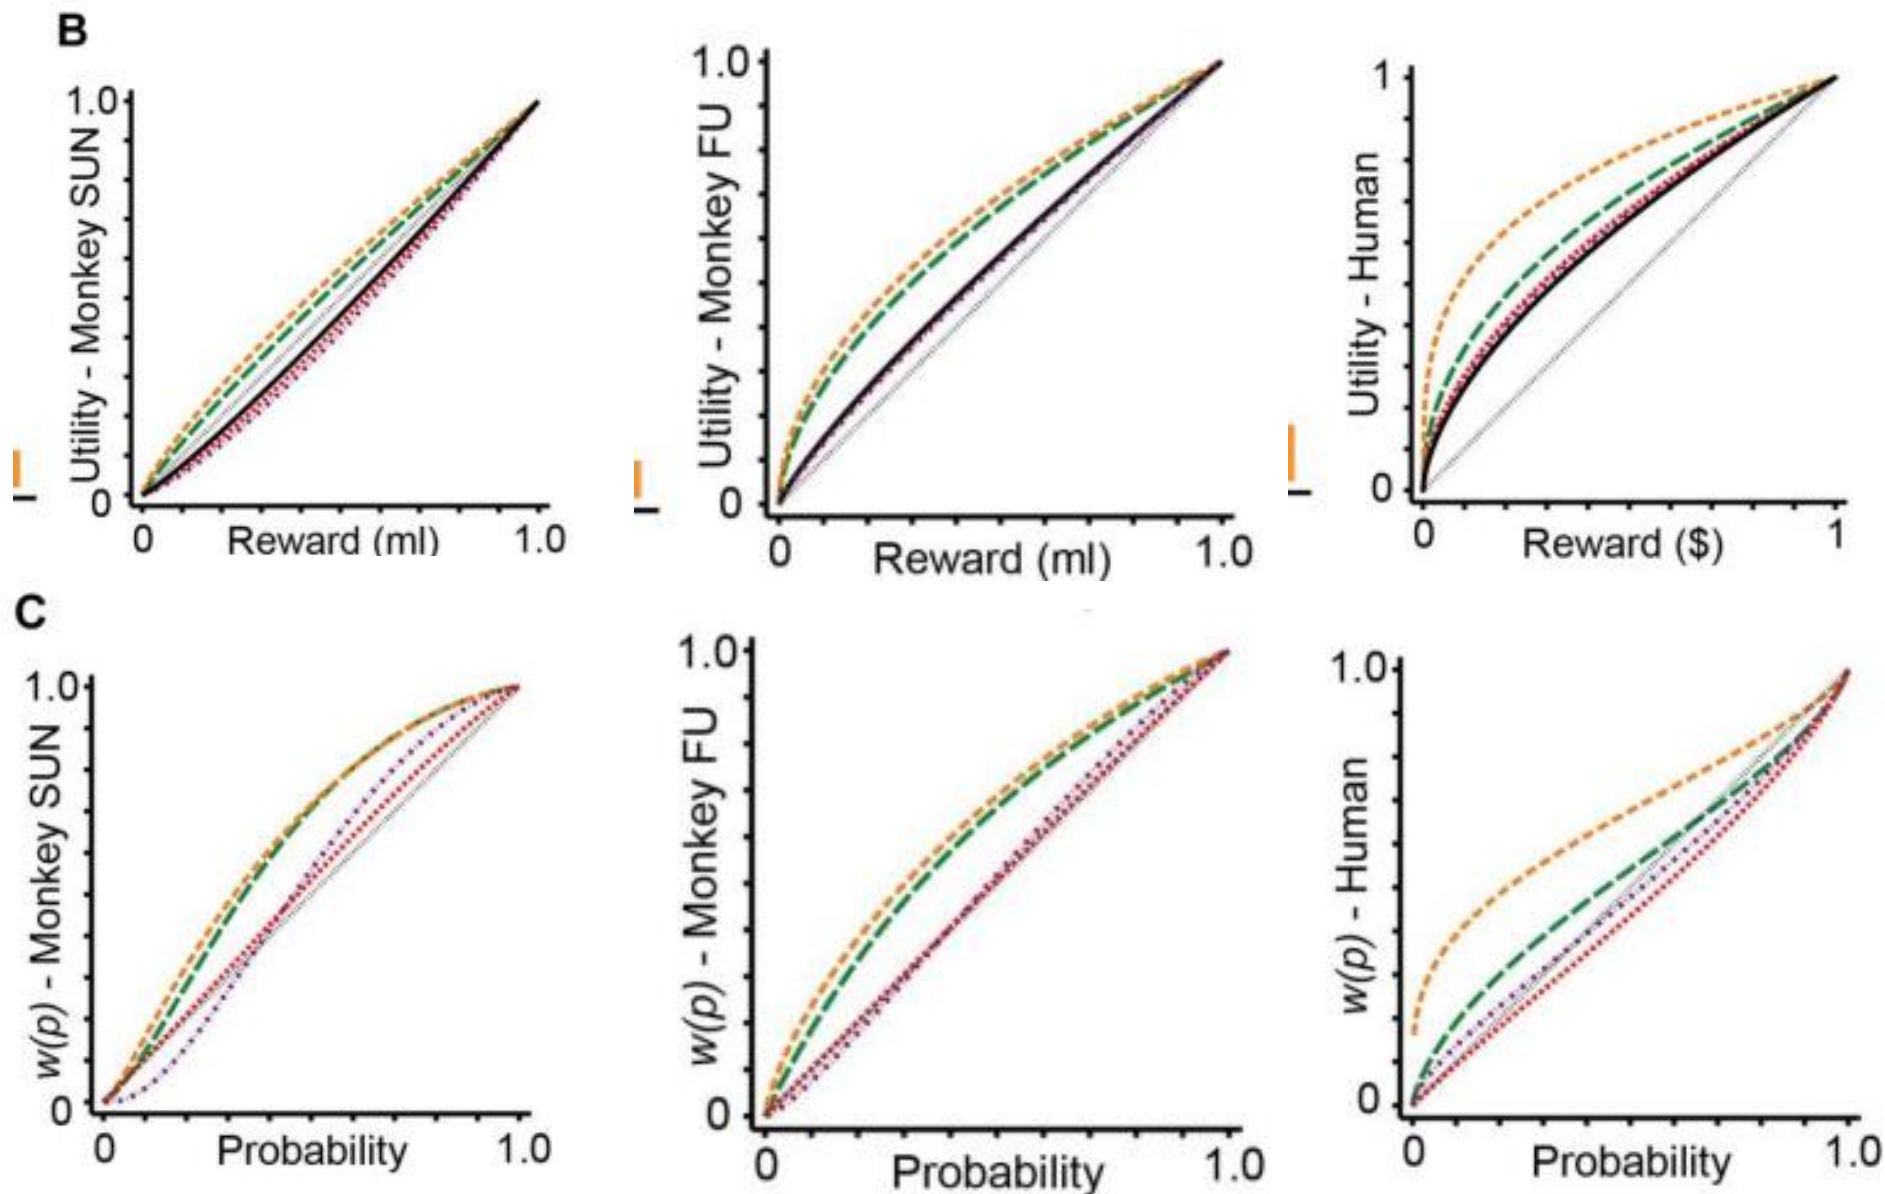
(v) P2: prospect theory with  $w(p)$  with two parameters as in Prelec (63)

$$V(m, p) = \exp[-\delta(-\log p)^\gamma] m^\alpha$$

- 2つの自由パラメーター
- ヒト→効用関数の曲率
- サル→確率加重関数



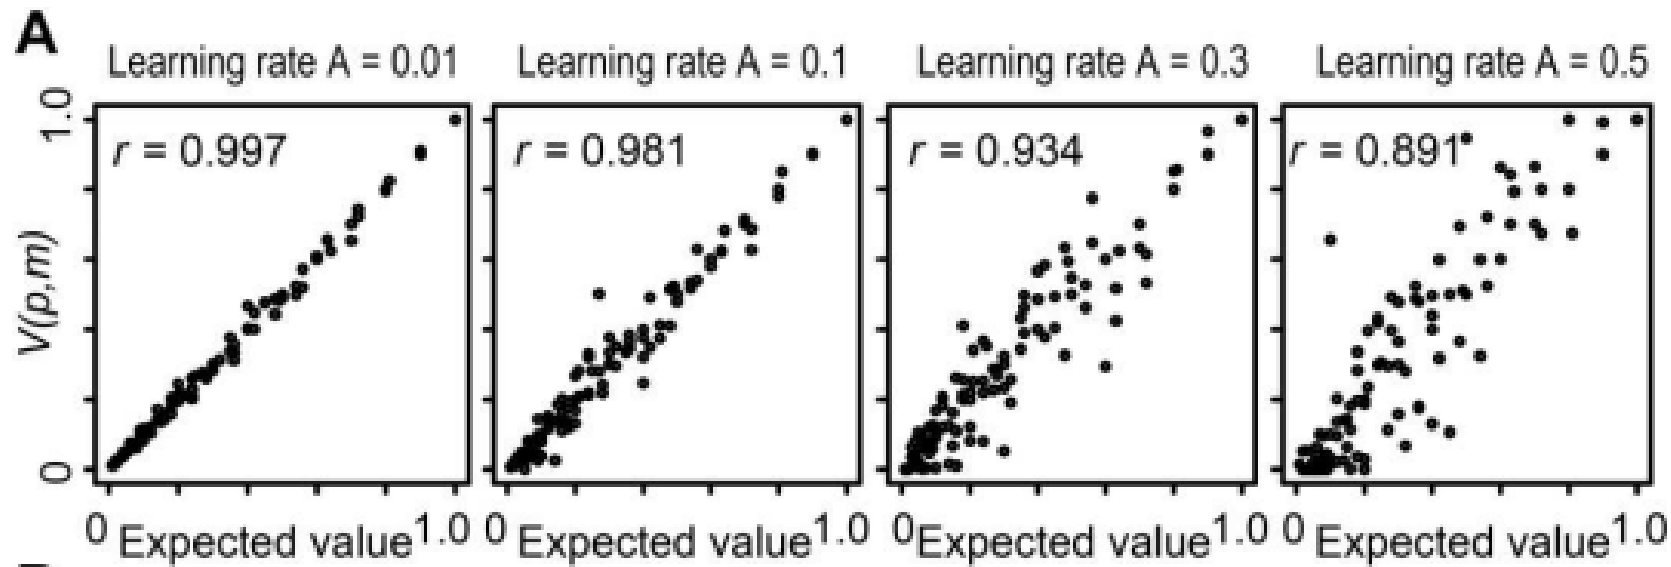
# プロスペクト理論パラメータの推定





# 強化学習モデル

- 受け取った報酬とくじの予測値の差 RPE
- サルも期待値を計算した
- 学習率が上がるとデータの揺らぎが大きくなる



# 動的プロスペクト理論

---

## 3つの仮定

- ・ BIC値に基づいて、P2をベースラインの確率加重モデルとして使用した
- ・ RPEが効用関数と確率加重関数の両方のパラメータに影響を与えるように
- ・ RPEは期待値と報酬から $\Delta_t = r_t - p_t m_t$ として導出される

# 動的プロスペクト理論

---

## 2つの方法でモデルを統合

- ・ プロスペクト理論のパラメーターは1つ前の試行のRPEに依存
- ・ プロスペクト理論のパラメーターは1つ前の試行の無報酬の場合と報酬がもらえた場合の2つのRPEに依存

どちらが適切？

# 動的プロスペクト理論

---

## ノンパラメトリック検定

- ・ 正と負のRPEがサルとヒトのリスクテイキング行動に影響するか？

正と負のRPEは分けて考えるべき

# 結果の要約

---

- 確率加重関数はとくに正のRPEの影響を受ける
- 負のRPEの影響は種間で差がある

# まとめ

---

## プロスペクト理論

➡ どういったリスクをとるかに焦

## 強化学習理論

➡ リスク選択のあとの結果からの学習に焦点

## 動的プロスペクト理論

## ヒトとサルの比較

